

Aplicación de Técnicas de Ciencia de Datos en el Análisis de Transacciones Financieras Fraudulentas

JUAN MOSQUERA,¹ AND MARIA MOSQUERA,²

(juan.mosquerap@udea.edu.co)

(mpaula.mosquera@udea.edu.co)

^{1,2}*Departamento de Ingeniería de Sistemas, Facultad de Ingeniería, Universidad de Antioquia, Medellín, Colombia*

El presente proyecto realiza un análisis integral del conjunto de datos disponible en Kaggle, enfocado en el estudio de transacciones financieras fraudulentas y su comportamiento en un entorno transaccional de alta concurrencia. El propósito analítico en comprender los patrones y factores asociados al fraude financiero con el fin de apoyar en futuras investigaciones de aprobación o rechazo de transacciones en tiempo real. La metodología aplicada fue mediante etapas de exploración y preparación de datos, técnicas de análisis estadísticos, visualización de graficas para identificar distribuciones, relación entre variables y comportamientos atípicos. Se realizan procesos de imputación, limpieza, transformación y escalamiento de datos con el fin de mejorar la calidad y coherencia analítica del conjunto de datos. Los resultados obtenidos permiten reconocer patrones de comportamiento relacionados con las transacciones fraudulentas, se realiza la interpretación de los resultados desde la perspectiva técnica y profesional, evidenciando la importancia del análisis y preprocesamiento de datos como etapas fundamentales para futuros sistemas inteligentes de detección de fraude financiero.

Keywords: Análisis de datos, preprocesamiento de datos, detección de anomalías, transacciones financieras, ciencia de datos

1 INTRODUCCIÓN

El crecimiento de las plataformas de pago electrónico y el comercio digital ha transformado la dinámica de las transacciones financieras a escala global. Según el Nilson Report [1], las pérdidas mundiales por fraude en pagos con tarjeta alcanzaron USD 33.83 mil millones en 2023 y se proyecta que aumenten a USD 403.88 mil millones en la próxima década, con el fraude en transacciones sin presencia física de tarjeta (CNP) modalidad predominante en el comercio electrónico, representando el 71% de las pérdidas en mercados como el estadounidense [2].

Este escenario ha convertido la detección temprana de anomalías financieras en una necesidad estratégica para instituciones bancarias, procesadores de pago y comercios, quienes asumen directamente las pérdidas derivadas de transacciones no autorizadas, robo de identidad y suplantación de usuarios. Ante este panorama, la ciencia de datos ha emergido como disciplina central para el desarrollo de sistemas de detección

de fraude, al proporcionar herramientas que permiten el análisis de grandes volúmenes de datos transaccionales e identificar patrones relevantes para la toma de decisiones en entornos financieros [3]. Los enfoques utilizados en la literatura han evolucionado desde sistemas basados en reglas explícitas hacia modelos de aprendizaje automático supervisado, como árboles de decisión, bosques aleatorios y redes neuronales, además de métodos de detección de anomalías como Isolation Forest y autoencoders.

Sin embargo, una limitación recurrente en trabajos de esta área es la poca atención prestada a las etapas previas al modelado como lo son la calidad del preprocesamiento, la comprensión del desbalance de clases y el diagnóstico de la estructura del dato condicionan directamente el desempeño de cualquier modelo, independientemente de su sofisticación algorítmica. En este sentido, el análisis exploratorio de datos constituye una etapa esencial para comprender la estructura, calidad y comportamiento de la información antes de realizar cualquier proceso analítico avanzado [4]. El presente trabajo, titulado Aplicación de Técnicas de Ciencia de Datos en el Análisis de Transacciones Financieras Fraudulentas, aborda esta brecha mediante un análisis exploratorio e integral del

conjunto de datos IEEE-CIS Fraud Detection¹, disponible en la plataforma Kaggle. Este dataset contiene información de transacciones reales de comercio electrónico aportadas por Vesta Corporation, con 434 variables que capturan características del dispositivo, el usuario, el comportamiento transaccional y el historial de uso. A diferencia de trabajos que utilizan este dataset directamente para entrenamiento de clasificadores, el enfoque de este trabajo se centra en la comprensión profunda del dato: su estructura, sus patrones de ausencia, sus distribuciones y las relaciones entre variables, como fundamento para una futura etapa de modelado sólido y reproducible. La metodología aplicada abarca las etapas fundamentales del análisis exploratorio de datos: caracterización estructural del conjunto, análisis univariado, bivariado y multivariado para identificar distribuciones, relaciones y tendencias, detección de valores atípicos mediante métodos estadísticos y de aprendizaje automático, e imputación, escalamiento y transformación de variables para mejorar la calidad analítica del conjunto. Todo el proceso se ejecutó en Google Colaboratory utilizando Python y las librerías estándar de ciencia de datos. El objetivo principal es analizar el comportamiento de las transacciones financieras e identificar los patrones y características que distinguen las operaciones legítimas de las fraudulentas, evaluando la calidad del dato y sus anomalías como paso previo a cualquier proceso de modelado predictivo. La relevancia de este objetivo radica en que los sistemas financieros modernos operan en entornos de alta concurrencia donde miles de transacciones se procesan simultáneamente en cuestión de milisegundos; en ese contexto, la calidad y organización de los datos son factores críticos que determinan la confiabilidad de los sistemas de monitoreo y detección. Comprender el comportamiento de la información antes de cualquier modelamiento es, en última instancia, el fundamento para la construcción de soluciones éticamente responsables y técnicamente robustas en el dominio de la seguridad financiera.

2 METODOLOGÍA

2.1 Fuente y características del conjunto de datos

El conjunto de datos para la *Aplicación de Técnicas de Ciencia de Datos en el Análisis de Transacciones Financieras Fraudulentas* corresponde al conjunto IEEE-CIS Fraud Detection, disponible en Kaggle[3]. El dataset fue publicado para una competencia académica patrocinada por IEEE Computational Intelligence Society (IEEE-CIS) en colaboración con Vesta Corporation, la cual es una empresa especializada en sistemas de pagos. Estos datos son provenientes de transacciones financieras reales, recopiladas en entornos de comercio electrónico durante un periodo aproximado de seis meses, lo cual es relevante y representativo del fenómeno estudiado.

¹ <https://www.kaggle.com/competitions/ieee-fraud-detection/data>

Dado que no todas las transacciones poseen registro de identidad asociado, la integración de ambos archivos mediante un left join introduce de forma estructural una alta proporción de valores faltantes en las variables de identidad, hecho que condiciona directamente las decisiones de imputación adoptadas en etapas posteriores.

El conjunto está distribuido en dos archivos principales, *train_transaction.csv* el cual contiene 590,540 registros, 394 variables y *train_identify.csv* con 144,233 registros, 41 variables, los cuales están relacionados mediante la llave TransactionID. En total son 434 características que están disponibles para el análisis. La variable objetivo es isFraud, de tipo binario, donde 1 indica cuando la transacción es fraudulenta y 0 una transacción legítima. Se presenta un desbalance en la distribución de clases, lo cual es esperado en detección de anomalías financieras, debido a que solo aproximadamente el 3.5% de transacciones son etiquetadas como fraude, esto es un patrón típico en conjuntos de datos de detección de anomalías financieras [5] que debe tenerse en cuenta en el análisis e interpretación de resultados.

Las variables se agrupan en las siguientes categorías:

- Variables transaccionales: monto de la transacción (TransactionAmt), marca temporal (TransactionDT), producto asociado (ProductCD) y código de tarjeta.
- Variables de comportamiento (C1–C14, D1–D15, V1–V339): contadores de uso, diferencias temporales y variables de Vesta relacionadas con el historial del usuario y del dispositivo.
- Variables categóricas: dirección de facturación (addr1, addr2), país del emisor (P_emaildomain, R_emaildomain) y canal de pago (card1–card6, M1–M9).
- Variables de identidad: tipo de dispositivo, información del navegador y del sistema operativo, y otras características de autenticación del usuario.

2.2 Análisis Exploratorio de Datos (EDA)

El análisis exploratorio de datos (EDA, por sus siglas en inglés) es definido por Tukey [6] como el conjunto de técnicas dirigidas a examinar los datos con el fin de descubrir estructuras subyacentes, detectar anomalías, formular hipótesis y verificar supuestos antes de aplicar técnicas de modelado formal. En el contexto de la ciencia de datos, el EDA constituye una etapa fundamental que permite comprender la calidad, distribución y comportamiento de la información disponible [4].

El análisis exploratorio se realizó en tres niveles de profundidad, para comprender la estructura, calidad y comportamiento del conjunto de datos, esto es antes de cualquier proceso de modelado, el cual no se va a realizar durante este proyecto.

Análisis univariado: El análisis univariado estudia cada variable de forma independiente para describir su distribución, forma y comportamiento central [7]. Se calcularon medidas de tendencia central (media, mediana, moda), de dispersión (desviación estándar) y de forma

(asimetría y curtosis) mediante la librería `scipy.stats` para las variables *TransactionDT* y *TransactionAmt*. Las distribuciones se visualizaron con histogramas superpuestos con la curva KDE y líneas de referencia para la media y la desviación estándar. Para *TransactionAmt* se aplicó escala logarítmica en el eje horizontal dado su alto nivel de asimetría positiva y para la variable objetivo *isFraud* se cuantificó el desbalance de clases mediante un gráfico de conteo con etiquetas de porcentaje.

Análisis bivariado: El análisis bivariado examina la relación o asociación entre dos variables simultáneamente, permitiendo identificar dependencias y diferencias de comportamiento entre grupos [7]. Se analizaron las relaciones entre variables independientes y la variable objetivo *isFraud* mediante: (i) gráficas de densidad KDE agrupadas por clase para *TransactionAmt* en escala logarítmica; (ii) gráficas de barras con tasas de fraude (%) para variables categóricas como *card4*, *ProductCD* y *DeviceType*; y (iii) prueba de independencia Chi-cuadrado (q) con cálculo de la V de Cramer para cuantificar la fuerza de asociación entre *DeviceType* e *isFraud*, evaluando estadísticamente la significancia de la relación detectada visualmente

Análisis multivariado: El análisis multivariado estudia simultáneamente tres o más variables para descubrir estructuras latentes y patrones de correlación conjunta [8]. Se construyó una matriz de correlación de Spearman sobre un conjunto de variables clave (*TransactionAmt*, *card1*, *card2*, *C1*, *C2*, *C11*, *C13*, *D1*, *isFraud*), visualizada mediante un mapa de calor con escala de -1 a 1. Adicionalmente, se realizó un diagnóstico de redundancia por bloques temáticos: subgrupo C (variables de conteo), subgrupo D (deltas temporales) y subgrupo V (atributos Vesta), utilizando matrices triangulares enmascaradas para facilitar la lectura. Se reportó automáticamente todo par de variables con correlación absoluta de Spearman superior a 0.85 como criterio de colinealidad crítica, orientando las decisiones de selección de variables en la etapa de transformación.

2.3 Detección de Valores Atípicos

Los valores atípicos son observaciones que se alejan significativamente del comportamiento general del conjunto de datos y pueden distorsionar los resultados del análisis si no se tratan adecuadamente [9]. Se implementaron y compararon tres técnicas de detección de valores atípicos con enfoques metodológicos distintos, aplicadas sobre un subconjunto de muestra de las variables *TransactionAmt* y *C1* (registros sin valores faltantes en ambas variables): **Rango Intercuartílico (IQR):** Enfoque estadístico univariado que identifica como atípicos los registros que superan el límite superior $Q3 + 1.5IQR$ sobre *TransactionAmt*. Es robusto ante distribuciones asimétricas [8] y no requiere supuestos de normalidad. **Isolation Forest (iForest):** Algoritmo de basado en árboles de aislamiento que detecta anomalías multivariadas según la facilidad con que una observación puede ser aislada del resto [8]. Se configuró con una tasa de contaminación del 3% lo cual es coherente con la prevalencia de fraude del dataset y semilla aleatoria

fija para reproducibilidad. **k-Nearest Neighbors (k-NN)** basado en distancias: Enfoque de densidad local que calcula el promedio de distancias a los 5 vecinos más cercanos de cada registro. Se estableció como atípico todo registro cuyo score fuera superior del percentil 97 de la distribución de distancias, equivalente a un nivel de contaminación simétrico al utilizado en Isolation Forest. Los resultados de las tres técnicas se visualizaron en un panel comparativo de diagramas de dispersión con escala logarítmica en ambos ejes, permitiendo contrastar los espacios de decisión de cada método. Se realizó además un cruce evaluativo con la variable *isFraud* para determinar qué porcentaje de fraudes reales capturaba cada técnica dentro del subconjunto analizado. Este enfoque orientado al dominio es esencial porque en el contexto de fraude financiero los valores extremos no siempre se deben a errores, pueden ser generalmente montos atípicamente altos o frecuencias de uso inusuales lo cual es precisamente la señal del fraude [5], por lo que la decisión de tratamiento se basa en el contexto del hallazgo, no en un criterio automático de eliminación.

2.4 Imputación de Datos Faltantes

La presencia de valores faltantes es uno de los principales desafíos del dataset, especialmente en las variables V (tasas de hasta el 86% en algunos atributos) y en las variables de identidad, cuya ausencia es estructural por diseño. Siguiendo los lineamientos de Little y Rubin [10] para el tratamiento de datos faltantes. El diagnóstico de valores faltantes reveló patrones de ausencia heterogéneos y estructuralmente diferenciados entre bloques de variables. Las variables transaccionales principales (*TransactionAmt*, *ProductCD*, *card1–card6*) presentaron tasas de ausencia inferiores al 5%, lo que las convierte en las características más completas del dataset. Las variables del bloque C mostraron tasas moderadas de entre el 5% y el 15%, mientras que el bloque D presentó mayor variabilidad, con algunos deltas temporales superando el 50% de ausencia. El caso más crítico corresponde al bloque V: de las 339 variables Vesta, numerosos subgrupos presentaron tasas de faltantes superiores al 70%, con casos extremos cercanos al 86%, lo que implica que en esas columnas apenas uno de cada siete registros tiene valor observado. Las variables de identidad, por su parte, presentan ausencia estructural en el 75.6% de los registros, exactamente los 446,308 registros que no tienen entrada correspondiente en *train_identity.csv*, situación que no responde a errores de captura sino al diseño relacional del dataset. Este diagnóstico diferenciado fue determinante para diseñar la estrategia de imputación por fases descrita a continuación, evitando aplicar un tratamiento uniforme a patrones de ausencia con causas y consecuencias radicalmente distintas.

Se diseñó un pipeline de imputación mixta en cinco fases: Fase 1 — Ingeniería de indicadores: Antes de imputar, se crearon variables indicadoras binarias para preservar la información contenida en el patrón de ausencia. Para las variables críticas de identidad *DeviceType* e *id_31* se generaron los indicadores *DeviceType.was null*

e `id_31_was_null`. Adicionalmente se incorporó la bandera `is_outlier_knn` derivada de la detección de atípicos de la etapa anterior. Esta técnica de indicador de ausencia fue aplicada debido a que permite que etapas posteriores capturar la información del patrón de faltantes como atributo predictivo [10].

Fase 2 — Imputación multivariada KNN: Para las variables de los bloques C (C1–C14), D (D1–D15) y *TransactionAmt*, variables altamente interrelacionadas según el análisis multivariado, se aplicó el *KNNImputer* de *scikit-learn* con $k = 5$ vecinos. Previo a la imputación se aplicó escalamiento *MinMax* temporal para equilibrar las distancias geométricas entre variables de diferente magnitud, y al finalizar se restableció la transformación para recuperar las unidades originales. Este enfoque multivariado preserva las relaciones de correlación entre variables en lugar de imputar cada columna de forma independiente [10].

Fase 3 — Imputación tradicional: Las variables numéricas restantes no incluidas en el bloque KNN se imputaron con la mediana de cada columna. Las variables categóricas (incluyendo las de identidad) se imputaron asignando la etiqueta 'Unknown', codificando explícitamente la ausencia como categoría propia y preservando la señal de no disponibilidad de información.

Fase 4 — Escalamiento operacional: Una vez completada la imputación, se aplicó estandarización Z-score (*StandardScaler*) sobre *TransactionAmt*, generando la variable derivada *TransactionAmt_scaled* con media cero y varianza unitaria para uso en análisis comparativos posteriores.

Fase 5 — Auditoría de integridad: Al finalizar el pipeline se verificó que el total de valores nulos remanentes en la matriz fuera cero, confirmando la integridad del proceso de imputación. La estructura final de la matriz limpia conservó los 590,540 registros originales.

2.5 Transformación y Tratamiento de Variables

El tratamiento de variables se orientó a mejorar la calidad analítica del conjunto y preparar los datos para su uso en modelos futuros. Los criterios aplicados fueron: Codificación de variables categóricas: Las variables nominales con cardinalidad reducida (como *ProductCD* y *card4*) se transformaron mediante One-Hot Encoding. Para variables con alta cardinalidad (dominios de correo, campos de dirección), se aplicó codificación por frecuencia, evitando una expansión excesiva de dimensionalidad [11]. Escalamiento de variables numéricas: Se aplicó escalamiento diferenciado según la distribución de cada variable. *MinMaxScaler* se utilizó como paso previo a la imputación KNN para equilibrar distancias geométricas; *StandardScaler* se aplicó sobre *TransactionAmt* para el escalamiento operacional final. Variables con alta asimetría positiva se visualizaron en escala logarítmica durante el EDA, técnica que comprime la escala y reduce la influencia de valores extremos en las interpretaciones gráficas [11]. Reducción de redundancia por bloques: El diagnóstico multivariado identificó pares de variables con colinealidad crítica:

$$(|r_s| > 0.85)$$

dentro de los bloques C, D y V lo cual orienta la selección de variables representativas por grupo en futuras etapas de modelado, reduciendo la redundancia informática sin pérdida significativa de información [8].

2.6 Herramientas y Librerías Utilizadas

El desarrollo del proyecto se realizó en el lenguaje de programación Python 3.11 mediante Google Colaboratory (Colab), entorno de notebooks Jupyter alojado en la nube de Google que no requiere instalación local, provee acceso a recursos computacionales compartidos (CPU/GPU) y dispone de las librerías de ciencia de datos preinstaladas en su imagen de ejecución. Esta elección facilitó el análisis iterativo, la colaboración en tiempo real entre los miembros del equipo y la documentación integrada de cada etapa del proceso analítico, garantizando además la reproducibilidad del flujo de trabajo sin dependencias de configuración local.

Las librerías empleadas fueron seleccionadas por su consolidación en la comunidad científica de ciencia de datos y por la complementariedad de sus funcionalidades en el contexto del proyecto. *pandas* (v2.1.4) constituyó la herramienta principal para la manipulación del dataset, incluyendo la integración de los archivos de transacciones e identidad mediante *left join*, el filtrado, la agrupación y el cálculo de estadísticas por subconjuntos de variables. *numpy* (v1.26.4) soportó las operaciones numéricas de bajo nivel, el cálculo de percentiles para los umbrales de detección de atípicos y las transformaciones matriciales requeridas en el pipeline de imputación.

Para la visualización, *matplotlib* (v3.10.0) permitió la generación de histogramas con curvas KDE, paneles comparativos de dispersión en escala logarítmica y gráficas de referencia con líneas de media y desviación estándar. *seaborn* (v0.13.2) complementó estas visualizaciones con mapas de calor para las matrices de correlación de Spearman, gráficas de densidad KDE segmentadas por clase y diagramas de barras para el análisis de tasas de fraude por variable categórica, aprovechando su integración nativa con *pandas* y su mayor expresividad estética para visualizaciones estadísticas complejas.

scikit-learn (v1.6.0) fue la librería de mayor alcance funcional en el proyecto: el *KNNImputer* para la imputación multivariada de los bloques C, D y *TransactionAmt*; el algoritmo *Isolation Forest* para la detección de anomalías multivariadas; y los escaladores *MinMaxScaler* y *StandardScaler* para el preprocesamiento previo a imputación KNN y el escalamiento operacional final, respectivamente. Finalmente, *scipy* (v1.13.1) fue

empleada para el cálculo de estadísticos de forma mediante *scipy.stats* asimetría y curtosis de *TransactionDT* y *TransactionAmt*, y para la ejecución de la prueba Chi-cuadrado (χ^2) de independencia entre *DeviceType* e *isFraud*, incluyendo el cálculo de la V de Cramer como medida de fuerza de asociación.

3 RESULTADOS Y ANÁLISIS

Se presentan los hallazgos obtenidos a lo largo del proceso de análisis exploratorio, detección de valores atípicos e imputación de datos, de acuerdo con las etapas metodológicas descritas anteriormente. En el contexto de fraude financiero, cada resultado tiene su interpretación crítica.

El dataset integrado resultó en una matriz de 140,856 registros y 434 variables, distribuidas en 399 de tipo float64, 31 de tipo object (categóricas) y 4 de tipo int64. Vale la pena notar que el dataset se ejecutó sobre una muestra de 140,856 registros en lugar de los 590,540 del conjunto completo debido a que son los registros que coincidían. La variable objetivo *isFraud* presentó 137,193 transacciones legítimas (97.40%) y 3,663 transacciones fraudulentas (2.60%), con-firmando el desbalance de clases característico del problema (Fig. 1).




Fig. 1. Distribución de Transacciones Fraudulentas (*isFraud*)

Los grupos de variables anónimas se distribuyeron en 14 variables C, 17 variables D, 9 variables M y 339 variables V, lo que refleja la alta dimensionalidad y heterogeneidad del conjunto. El desbalance de transacciones legítimas-clase mayoritaria con un porcentaje del 97.4% y transacciones fraudulentas-clase minoritaria con un porcentaje del 2.6% tiene implicaciones directas para cualquier etapa de modelado futura: un clasificador trivial que etiquete todas las transacciones como legítimas alcanzaría una precisión del 97.4%, lo que hace que la exactitud simple sea una métrica irrelevante y obliga al uso de métricas como precisión, recall, F1 o AUC-ROC para evaluar el desempeño real de detección [5].

3.1 Resultados del análisis exploratorio univariado

El análisis de *TransactionDT* reveló una distribución aproximadamente simétrica con asimetría de

$$-0.14$$

y curtosis de

$$-1.04$$

, indicando una forma más plana que la normal sin colas pesadas. La media fue de 1,498,633 s con una desviación estándar de 758,410 s, abarcando un rango de 86,400 s a 2,904,279 s (Fig. 2).




Fig. 2. Distribución de *TransactionDT* con Medidas de Dispersión

La curtosis negativa y la presencia de dos picos visibles en la distribución (distribución bimodal) sugieren que el periodo de observación captura dos franjas temporales de mayor actividad transaccional separadas en el tiempo, lo cual esta posiblemente relacionadas con comportamientos de compra estacionales o ciclos de facturación. El análisis de *TransactionAmt* evidenció una distribución fuertemente asimétrica positiva con asimetría de 6.93 y curtosis de 74.19, valores que indican la presencia de una cola derecha extremadamente larga y un comportamiento de distribución leptocúrtica (Fig. 3).




Fig. 3. Distribución de *TransactionAmt* con Medidas de Dispersión

La curtosis de 74.19 registrada en *TransactionAmt* merece un análisis específico por sus implicaciones metodológicas. Una curtosis tan elevada indica que la distribución es extremadamente leptocúrtica: las colas son tan pesadas que los valores extremos ocurren con una frecuencia muy superior a la que predeciría una distribución normal, invalidando el uso de la media como estimador central confiable de hecho, la media de USD 127.41 está considerablemente alejada de la concentración real de los datos, que se ubica en rangos de USD 30 a USD 100 según

la distribución visual. Esta característica tiene tres consecuencias directas sobre las decisiones metodológicas adoptadas: primero, justifica el uso de la mediana en lugar de la media para la imputación de valores faltantes en esta variable; segundo, hace al método Z-score poco confiable como detector de atípicos para TransactionAmt específicamente, ya que la desviación estándar queda inflada por los valores extremos, reduciendo la sensibilidad del umbral $|z| > 3$; y tercero, valida la necesidad de aplicar transformación logarítmica para comprimir la escala antes de cualquier proceso de modelado, dado que algoritmos sensibles a la magnitud de las variables como regresión logística o k-NN, serían dominados por los montos extremos en su forma original [11].

La media de USD 127.41 con un máximo de USD 5,094.95 y un mínimo de USD 0.29 confirma que la mayoría de las transacciones se concentran en montos bajos-medios, pero existen transacciones de monto muy elevado. Este comportamiento justifica el uso de escala logarítmica para el análisis visual y la aplicación de transformaciones de compresión en etapas de modelado. Una curtosis de

74.19 indica que los valores extremos no son escasos: son suficientemente frecuentes para distorsionar los estimadores estadísticos clásicos, lo que refuerza la necesidad de técnicas robustas de detección de atípicos.

3.2 Resultados del análisis bivariado

El análisis de densidad KDE de TransactionAmt segmentado por clase (Fig. 4).




Fig. 4. Densidad del Monto de Transacción por Clase

Revela que las transacciones fraudulentas presentan una distribución de montos notablemente más dispersa y con mayor peso relativo en valores intermedios-altos comparado con las legítimas, las cuales se concentran más marcadamente en montos bajos. Aunque las distribuciones se superponen considerablemente, la diferencia en la forma de las colas constituye una señal discriminante modesta pero consistente. El análisis por franquicia de tarjeta (card4) reveló diferencias en las tasas de fraude: Discover lidera con

7.73%, seguida de Visa (3.48%), Mastercard (3.43 %) y American Express con la tasa más baja (2.87%) (Fig. 5). La brecha entre American Express y el resto es especialmente relevante: su tasa de fraude es casi 3 veces menor que la de Mastercard, lo que podría reflejar diferencias en los protocolos de seguridad y verificación de cada red de pago, o en el perfil socioeconómico de sus usuarios. El análisis por ProductCD (Fig. 6) evidenció la mayor heterogeneidad de riesgo entre todas las variables categóricas evaluadas. La categoría C registra una tasa de fraude del 8.41%, superando en 3.2 veces la tasa general del dataset (2.60%), siendo la variable categórica con mayor poder discriminante identificada en el análisis bivariado: S (3.01%), H (1.94%), W (1.88%) y R (1.11%).

Este hallazgo es críticamente relevante: la categoría de producto C es un predictor categórico de alto riesgo y debería recibir tratamiento diferenciado en cualquier sistema de puntuación de riesgo, ya que su sola presencia multiplica por 3.2 la probabilidad basal de fraude.




Fig. 5. Tasa de Fraude (%) por Franquicia de Tarjeta (card4)




Fig. 6. Tasa de Fraude (%) por Tipo de Producto (ProductCD)

El análisis por DeviceType (Fig. 7) mostro' que los dispositivos móviles presentan una tasa de fraude del 4.86%, significativamente mayor que los dispositivos de escritorio (2.74%), representando un riesgo relativo 1.77 veces superior. Esta diferencia fue sometida a contraste estadístico formal mediante la prueba Chi-cuadrado de independencia aplicada sobre una tabla de contingencia de 58,214 registros con información de dispositivo disponible, que arrojó los siguientes resultados: $q(1) = 177.0002$, ($p = 2.19 \times 10^{-40}$), V de Cramer = 0.0551. El estadístico Chi-cuadrado de 177.00 con un p-valor prácticamente nulo (2.19×10^{-4}) permite rechazar con plena confianza estadística la hipótesis nula de independencia entre el tipo de dispositivo y la ocurrencia de fraude: la relación observada no es producto del azar. Sin embargo, la V de Cramer de 0.0551 revela que, pese a ser estadísticamente significativa, la fuerza de asociación entre ambas variables es débil, lo que indica que DeviceType es un predictor relevante pero insuficiente por sí solo para discriminar el fraude: su valor reside en la combinación con otras variables dentro de un modelo multivariado. Esta distinción entre significancia estadística y relevancia práctica es fundamental en datasets de gran tamaño, donde incluso asociaciones débiles alcanzan significancia por el volumen de registros [7]. La mayor vulnerabilidad del canal móvil puede estar asociada a factores como autenticación más débil, uso de redes Wi-Fi públicas o aplicaciones de pago con menor nivel de protección antifraude.




Fig. 7. Tasa de Fraude (%) por Tipo de Dispositivo (DeviceType)

3.3 Resultados del análisis multivariado

La matriz de correlación de Spearman (Fig. 8) reveló que las variables de conteo del bloque C son las que presentan mayor correlación con *isFraud*: C2 ($r_s = 0.115$), C11 ($r_s = 0.110$) y C1 ($r_s = 0.107$). Aunque estas correlaciones son modestas en magnitud, son consistentes entre sí y apuntan a que el historial de uso (frecuencia de transacciones, conteo de dispositivos y cuentas asociadas) es más informativo para distinguir fraude que el monto de la transacción (r_s

$= 0.005$), resultado contrario a la intuición, pero coherente con la literatura sobre fraude en e-commerce [5]. Variables como card1, card2, C13 y D1 mostraron correlaciones negativas débiles (-0.01 a -0.025), lo que indica asociación inversa marginal.




Fig. 8. Matriz de Correlación de Spearman: Variables Clave vs isFraud

El diagnóstico de redundancia por bloques (Fig. 9) identificó 11 pares de variables con colinealidad crítica ($|r_s| > 0.85$) distribuidos en tres bloques:

Bloque C: C14 $\leftrightarrow$ C1 ($r_s = 0.8503$) — un único par crítico.

Bloque D: D2 $\leftrightarrow$ D1 ($r_s = 0.9844$) y D5 $\leftrightarrow$ D3 ($r_s = 0.8761$) — los deltas temporales D1-D2 son prácticamente redundantes.

Bloque V: 8 pares críticos centrados en el grupo V10-V11-V29-V30 (r_s entre 0.91 y 0.99) y el par V53-V54




Fig. 9. Análisis Multivariado de Redundancia por bloque

($r_s = 0.94$), evidenciando fuertes agrupaciones de variables Vesta casi idénticas. El hallazgo más crítico es D2 $\leftrightarrow$ D1 con $r_s = 0.9844$: estas dos variables son prácticamente intercambiables y mantenerlas simultáneamente en un modelo introduciría multicolinealidad severa. En el bloque V, la existencia de grupos enteros de variables con correlaciones superiores a 0.91 sugiere que Vesta genera múltiples versiones de un mismo indicador base, lo que permite reducir este bloque

drásticamente sin pérdida de información.

3. 4 Resultados de la detección de valores atípicos

La comparación de las tres técnicas de detección sobre 140,855 registros, rango intercuartílico (Fig. 10), Isolation Forest (Fig. 11), k-NN (Fig.12) reveló diferencias sustanciales tanto en el volumen de atípicos detectados como en su capacidad de captura de fraudes reales.




Fig. 10. Detección de Atípicos rango intercuartílico




Fig. 11. Detección de Atípicos Isolation Forest




Fig. 12. Detección de Atípicos k-NN

El método IQR detectó 15,418 registros atípicos (10.9% del subconjunto), un volumen considerablemente mayor que los métodos de machine learning (4,226 cada uno). Sin embargo, del total de fraudes reales presentes en el subconjunto, el IQR capturó solo el 15.1%, mientras que k-NN capturó el 8.1% e Isolation Forest el 7.0%. Este resultado aparentemente contradictorio —mayor detección absoluta de IQR pero proporciones de fraude similares a los otros métodos— revela que el IQR tiene alta tasa de falsos positivos: la mayoría de los 15,418 registros marcados como atípicos son transacciones de monto elevado legítimas, no fraudes. Críticamente, ningún método capturó más del 15% de los fraudes al buscar atípicos, lo que confirma la premisa metodológica: el fraude en este dataset no se manifiesta principalmente como outlier en el espacio (monto, conteo), sino como una combinación sutil de comportamientos en múltiples dimensiones que requiere modelos supervisados para su detección efectiva [5]. Los valores atípicos detectados no fueron eliminados del dataset por esta razón: se preservaron y se marcaron con la variable indicadora `is_outlier_knn` para que el comportamiento atípico sea explotable como señal en etapas futuras.

La diferencia en el volumen de detección entre IQR (15,418 registros) e Isolation Forest y k-NN (4,226 cada uno) refleja una diferencia conceptual profunda entre los enfoques. El IQR opera sobre una sola dimensión, el monto de la transacción, con un límite fijo de USD 246.04, lo que implica que cualquier transacción por encima de ese valor es marcada como atípica independientemente de su contexto: un usuario habitual con historial de compras altas quedaría marcado igual que un defraudador. Isolation Forest y k-NN, en cambio, evalúan la anomalía en el espacio bidimensional (monto, conteo C1), considerando la densidad local del punto respecto a sus vecinos, lo que les permite distinguir observaciones genuinamente aisladas de aquellas que simplemente tienen valores altos en una dimensión, pero son consistentes con su entorno multivariado. El hecho de que ambos métodos de machine learning convergieran en exactamente el mismo número de atípicos (4,226) no es casualidad:

ambos fueron configurados con una tasa de contaminación del 3%, forzando por diseño que marquen el mismo porcentaje del subconjunto. Esto constituye una limitación propia del experimento: la tasa de contaminación es un hiperparámetro que el analista define a priori, y distintas elecciones producirían resultados diferentes. En consecuencia, los tres métodos deben interpretarse como herramientas complementarias de diagnóstico, no como verdades absolutas sobre cuáles registros son atípicos.

3.5 Resultados del proceso de imputación y preparación de datos

El pipeline de imputación mixta procesó el dataset en cinco fases, resultando en una matriz limpia de 140,856 registros y 439 variables (5 columnas adicionales generadas: indicadores de ausencia, bandera de outlier y TransactionAmt scaled). La auditoría final confirmó cero valores nulos remanentes en toda la matriz, garantizando la integridad del conjunto para etapas de modelado. La imputación KNN multivariada se aplicó sobre 22 variables de los bloques C, D y TransactionAmt, aprovechando las correlaciones detectadas en el análisis multivariado (hasta $r_s = 0.9844$ entre D1-D2) para estimar los faltantes de forma más precisa que la simple mediana. Las 383 variables numéricas restantes fueron imputadas con mediana y las 31 categóricas con la etiqueta 'Unknown', convirtiendo la ausencia de información de identidad en una categoría explícita que podría correlacionar con mayor riesgo de fraude. Desde una perspectiva crítica, la estrategia de imputación adoptada tiene una implicación importante: al imputar con mediana las variables V (que presentan hasta 86% de faltantes), se está introduciendo un volumen considerable de valores sintéticos que podrían comprimir artificialmente la varianza de esas variables. Esto no representa un problema para el análisis exploratorio, pero deberá considerarse en fases de modelado, donde un tratamiento alternativo como la eliminación de columnas con alta tasa de ausencia o la imputación por modelos específicos podría ser preferible.

4 CONCLUSIONES

El presente trabajo llevó a cabo un análisis exploratorio integral del conjunto de datos IEEE-CIS Fraud Detection, abarcando la caracterización estructural, el análisis univariado, bivariado y multivariado, la detección de valores atípicos mediante tres enfoques complementarios y la preparación completa del dataset a través de un pipeline de imputación mixta de cinco fases. El proceso demostró que las etapas previas al modelado no son solamente técnicas, sino analíticamente significativas: cada decisión de preprocesamiento reveló información relevante sobre el fenómeno del fraude financiero y condicionó la calidad del dato final.

Entre los hallazgos más relevantes se destaca que el comportamiento histórico del usuario, representado por las variables de conteo del bloque C (C2, C11, C1), resultó

más correlacionado con la ocurrencia de fraude que el monto de la transacción, resultado contraintuitivo pero coherente con la literatura del dominio [5]. El análisis bivariado identificó diferencias de riesgo significativas entre categorías: la categoría C de *ProductCD* presentó una tasa de fraude del 8.41%, 3.2 veces superior a la tasa general del dataset (2.60%), y los dispositivos móviles mostraron una vulnerabilidad 1.77 veces mayor que los de escritorio (4.86% vs 2.74%), diferencia respaldada estadísticamente mediante la prueba Chi-cuadrado ($\chi^2(1) = 177.00$, $p = 2.19 \times 10^{-40}$, V de Cramer = 0.055). Por su parte, el diagnóstico de redundancia multivariada identificó 11 pares de variables con colinealidad crítica, incluyendo D2 ↔ D1 con $r_s = 0.9844$ y grupos enteros de variables Vesta con correlaciones superiores a 0.91, lo que establece una hoja de ruta concreta para reducir drásticamente la dimensionalidad del bloque V sin pérdida de información en etapas futuras.

La comparación de técnicas de detección de valores atípicos aportó una conclusión crítica para el diseño de sistemas de detección: ningún método no supervisado — IQR, Isolation Forest ni k-NN — capturó más del 15.1% de los fraudes reales al buscar anomalías en el espacio de monto y conteo. Esto confirma que el fraude en este dataset no se manifiesta como una anomalía geométrica simple, sino como una combinación sutil de comportamientos en múltiples dimensiones que requiere modelos supervisados para su detección efectiva. En consecuencia, los registros atípicos detectados no fueron eliminados, sino preservados y marcados mediante la variable indicadora *is_outlier_knn*, convirtiéndolos en una señal potencialmente explotable en etapas de modelado.

El trabajo presenta limitaciones que deben considerarse en la interpretación de los resultados. La principal restricción fue de orden computacional: por limitaciones de memoria RAM en Google Colab, el análisis se ejecutó sobre 140,856 registros (el 23.9% del dataset original de 590,540), lo que podría no representar fielmente la distribución completa del fenómeno. Adicionalmente, las categorías de *ProductCD* y la totalidad de las variables V permanecen anónimas por acuerdo de confidencialidad con Vesta Corporation, lo que limita la interpretación de negocio de varios hallazgos. Desde el punto de vista metodológico, la imputación por mediana aplicada a variables con hasta el 86% de valores faltantes introduce un volumen considerable de valores sintéticos que podría comprimir artificialmente la varianza de esas columnas.

Finalmente, el desbalance severo de clases (97.40% / 2.60%) fue caracterizado, pero no tratado en esta etapa, lo que constituye un prerequisite indispensable antes de entrenar cualquier modelo clasificador.

Como extensión natural del trabajo, se propone continuar con la etapa de modelado supervisado empleando algoritmos de ensamble como Random Forest, XGBoost o LightGBM sobre la matriz limpia generada, incorporando técnicas de balanceo de clases como SMOTE y evaluando el desempeño mediante métricas adecuadas para contextos desbalanceados (AUC-ROC, F1-score y precisión recall). En paralelo, se recomienda replicar el análisis sobre el dataset completo en entornos con mayor capacidad de cómputo, aplicar reducción formal de dimensionalidad sobre los bloques D y V mediante PCA o selección basada en importancia, y evaluar estrategias alternativas de imputación para variables con alta tasa de

ausencia. Desde la perspectiva del análisis temporal, la distribución bimodal observada en *TransactionDT* sugiere la existencia de patrones cíclicos de fraude que podrían explorarse mediante análisis de series de tiempo, aportando valor adicional para sistemas de detección en tiempo real.

En síntesis, este trabajo ratifica que el análisis exploratorio y el preprocesamiento de datos no son pasos triviales de limpieza, sino etapas de generación de conocimiento que determinan la solidez de cualquier solución analítica posterior. La comprensión profunda de la estructura, calidad y comportamiento del dato es el fundamento sobre el cual se construyen sistemas inteligentes de detección de fraude financiero éticamente responsables y técnicamente robustos [4].

5 REFERENCES

- [1] The Nilson Report, “Payment Card Fraud Losses Worldwide in 2023,” Tech. Rep. 11, HSN Consultants, Inc. (2025), issue 1296, January 2025.
- [2] FICO, “Card-Not-Present Fraud Remains a Leading Concern as Payment Systems Evolve,” <https://www.fico.com/blogs/card-not-present-fraud-remains-leading-concern-payment-systems-evolve> (2025), accessed: May 24, 2026.
- [3] Kaggle, “IEEE-CIS Fraud Detection,” <https://www.kaggle.com/competitions/ieee-fraud-detection/data> (2019), accessed: May 22, 2026.
- [4] F. Provost and T. Fawcett, *Data Science for Business*, 2 (O’Reilly Media, 2013).
- [5] A. D. Pozzolo, O. Caelen, R. A. Johnson, and G. Bontempi, “Calibrating probability with undersampling for unbalanced classification,” in *Proc. IEEE Symp. Comput. Intell. Data Mining (CIDM)*, 4, pp. 159–166, Orlando, FL (2015).
- [6] J. W. Tukey, *Exploratory Data Analysis*, 5 (Addison-Wesley, Reading, MA, 1977).
- [7] R. Johnson and D. Wichern, *Applied Multivariate Statistical Analysis*, 6 (Pearson Prentice Hall, Upper Saddle River, NJ, 2007), 6th ed.
- [8] J. F. Hair, W. C. Black, B. J. Babin, and R. E. Anderson, *Multivariate Data Analysis*, 7 (Cengage Learning, 2019), 8th ed.
- [9] D. C. Hoaglin, F. Mosteller, and J. W. Tukey, *Understanding Robust and Exploratory Data Analysis*, 8 (Wiley, New York, 1983).
- [10] R. J. A. Little and D. B. Rubin, *Statistical Analysis with Missing Data*, 9 (Wiley, Hoboken, NJ, 2019), 3rd ed.
- [11] W. McKinney, *Python for Data Analysis*, 10 (O’Reilly Media, Sebastopol, CA, 2022), 3rd ed.