

Aplicación de Técnicas de Ciencia de Datos en el Análisis de Transacciones Financieras Fraudulentas

JUAN MOSQUERA,¹ AND MARIA MOSQUERA,²

(juan.mosquerap@udea.edu.co)

(mpaula.mosquera@udea.edu.co)

^{1,2}*Departamento de Ingeniería de Sistemas, Facultad de Ingeniería, Universidad de Antioquia, Medellín, Colombia*

El presente trabajo aplica técnicas de ciencia de datos para el análisis de transacciones financieras fraudulentas utilizando el conjunto de datos IEEE-CIS Fraud Detection, compuesto por 155,504 registros y 434 variables. El objetivo principal es identificar los patrones y características que distinguen las transacciones legítimas de las fraudulentas como fundamento para futuros sistemas de detección en tiempo real. La metodología se estructuró en cuatro etapas secuenciales: diagnóstico de datos, limpieza e imputación, análisis exploratorio de datos (EDA) y codificación de variables. Durante el diagnóstico se identificó un desbalance severo de clases (97.32% legítimas, 2.68% fraudulentas) y patrones de ausencia heterogéneos que motivaron la eliminación de 127 variables con más del 50% de valores faltantes y correlación inferior a 0.05 con la variable objetivo, reduciendo el conjunto a 307 variables. El análisis exploratorio, ejecutado sobre el dataset completo y limpio, identificó como características más influyentes en el fraude las variables del grupo Vesta (V244, V242, V246) con correlaciones de Spearman superiores a 0.30, seguidas de variables categóricas como *ProductCD* (categoría C: 8.71% de fraude) y *DeviceType* (móvil: 5.45% vs escritorio: 2.99%, $\chi^2=228.33$, $p=1.37 \times 10^{-51}$). Los resultados evidencian que el preprocesamiento riguroso y el análisis exploratorio orientado al dominio son etapas determinantes para la construcción de soluciones confiables de detección de fraude financiero.

Keywords: Análisis exploratorio de datos, detección de fraude financiero, preprocesamiento de datos, transacciones electrónicas, ciencia de datos

1 INTRODUCCIÓN

El crecimiento sostenido de las plataformas de pago electrónico y el comercio digital ha transformado profundamente la dinámica de las transacciones financieras a escala global. Según el Nilson Report [1], las pérdidas mundiales por fraude en pagos con tarjeta alcanzaron USD 33.83 mil millones en 2023 y se proyecta que acumulen USD 403.88 mil millones en la próxima década, con el fraude en transacciones sin presencia física de tarjeta (CNP) —modalidad predominante en el comercio electrónico— representando el 71% de las pérdidas en mercados como el estadounidense [2]. Este escenario ha convertido la detección temprana de anomalías financieras en una necesidad estratégica para instituciones bancarias, procesadores de pago y comercios en todo el mundo, quienes asumen directamente las pérdidas

derivadas de transacciones no autorizadas, robo de identidad y suplantación de usuarios. Según LexisNexis Risk Solutions [3], las empresas en América Latina asumen un costo de fraude equivalente a 3.9 veces el valor nominal perdido en transacciones fraudulentas, evidenciando que el impacto del fraude financiero digital trasciende la pérdida económica inmediata y compromete la confianza en los ecosistemas de pago digital como motor del desarrollo económico global.

Ante este panorama, la ciencia de datos ha emergido como disciplina central para el desarrollo de sistemas de detección de fraude, al proporcionar herramientas que permiten el análisis de grandes volúmenes de datos transaccionales e identificar patrones relevantes para la toma de decisiones en entornos financieros [4]. Los enfoques utilizados en la literatura han evolucionado desde sistemas basados en reglas explícitas hacia modelos de aprendizaje automático supervisado —como árboles de decisión, bosques aleatorios y redes neuronales— y métodos de detección de anomalías no supervisados como Isolation Forest y autoencoders [5]. Sin embargo, una limitación recur-

rente en trabajos de esta área es la insuficiente atención prestada a las etapas previas al modelado: la calidad del preprocesamiento, la comprensión del desbalance de clases y el diagnóstico estructural del dato condicionan directamente el desempeño de cualquier modelo, independientemente de su sofisticación algorítmica [6]. En este sentido, el análisis exploratorio de datos constituye una etapa esencial e irremplazable para comprender la estructura, calidad y comportamiento de la información antes de realizar cualquier proceso analítico avanzado [7].

El presente trabajo utiliza el conjunto de datos IEEE-CIS Fraud Detection¹, publicado en la plataforma Kaggle en el marco de una competencia académica patrocinada por IEEE Computational Intelligence Society (IEEE-CIS) en colaboración con Vesta Corporation, empresa estadounidense especializada en sistemas de pago garantizado para comercio electrónico. El dataset contiene 155,504 registros de transacciones financieras reales del mercado estadounidense, distribuidos en 434 variables que capturan características del dispositivo, el usuario, el comportamiento transaccional y el historial de uso. Su relevancia como benchmark en la comunidad científica radica en que representa un caso real de fraude financiero en e-commerce con un marcado desbalance de clases —el 2.68% de las transacciones corresponden a fraude— que reproduce fielmente las condiciones que enfrentan los sistemas transaccionales en producción [5]. A diferencia de trabajos que utilizan este dataset directamente para el entrenamiento de clasificadores, el enfoque de este trabajo se centra en la comprensión profunda del dato mediante un proceso metodológico estructurado en cuatro etapas secuenciales: diagnóstico de datos, limpieza e imputación, análisis exploratorio de datos (EDA) y codificación de variables.

El objetivo principal es identificar los patrones y características que distinguen las operaciones legítimas de las fraudulentas, evaluando la calidad del dato y determinando cuáles variables son influyentes en la ocurrencia de fraude financiero, como paso previo a cualquier proceso de modelado predictivo. La relevancia de este objetivo radica en que los sistemas financieros modernos operan en entornos de alta concurrencia donde miles de transacciones se procesan simultáneamente en cuestión de milisegundos; en ese contexto, la calidad y organización de los datos son factores críticos que determinan la confiabilidad de los sistemas de monitoreo y detección en tiempo real. Comprender el comportamiento de la información antes de cualquier modelamiento es, en última instancia, el fundamento para la construcción de soluciones éticamente responsables y técnicamente robustas en el dominio de la seguridad financiera, donde la velocidad y precisión en la identificación de patrones anómalos puede representar la diferencia entre prevenir o materializar una pérdida financiera [4].

2 METODOLOGÍA

2.1 Fuente y características del conjunto de datos

El conjunto de datos utilizado corresponde al IEEE-CIS Fraud Detection[8], disponible en la plataforma Kaggle. Fue publicado en el marco de una competencia académica patrocinada por IEEE Computational Intelligence Society (IEEE-CIS) en colaboración con Vesta Corporation, empresa estadounidense especializada en sistemas de pago garantizado para comercio electrónico. Los registros provienen de transacciones financieras reales recopiladas durante un periodo aproximado de seis meses, lo que le confiere alta representatividad del fenómeno estudiado.

El dataset se distribuye en dos archivos relacionales: *train.transaction.csv* y *train.identity.csv*, vinculados mediante la llave primaria *TransactionID*. El archivo de transacciones contiene 590,540 registros y 394 variables; el archivo de identidad cuenta con 144,233 registros y 41 variables. La integración de ambos archivos se realizó mediante un *left join* sobre *TransactionID*, resultando en una matriz inicial de 155,504 registros y 434 variables disponibles para el análisis. Dado que no todas las transacciones poseen registro de identidad asociado, esta operación introduce de forma estructural una alta proporción de valores faltantes en las variables de identidad.

La variable objetivo es *isFraud*, de tipo binario (0: legítima, 1: fraude). Su distribución evidenció un marcado desbalance de clases: 151,332 transacciones legítimas (97.32%) y 4,172 transacciones fraudulentas (2.68%), patrón típico en conjuntos de datos de detección de anomalías financieras que debe tenerse en cuenta en el análisis e interpretación de resultados [5]. Las variables del dataset se agrupan en las siguientes categorías:

- **Variables transaccionales:** monto (*TransactionAmt*), marca temporal (*TransactionDT*), producto asociado (*ProductCD*) y datos de tarjeta (*card1*–*card6*).
- **Variables de comportamiento** (*C1*–*C14*, *D1*–*D15*): contadores de uso y diferencias temporales que capturan el historial de interacción del usuario con el sistema de pagos.
- **Variables de Vesta** (*V1*–*V339*): características propietarias con alto porcentaje de valores faltantes en varios subgrupos.
- **Variables categóricas:** dirección de facturación (*addr1*, *addr2*), dominios de correo (*P_emaildomain*, *R_emaildomain*) y marcadores de coincidencia (*M1*–*M9*).
- **Variables de identidad:** tipo de dispositivo, sistema operativo, navegador y atributos de autenticación del usuario (*id_01*–*id_38*, *DeviceType*, *DeviceInfo*).

2.2 Diagnóstico y limpieza de datos

La metodología aplicada siguió un orden secuencial estricto: diagnóstico de datos, limpieza e imputación, análisis

¹ <https://www.kaggle.com/competitions/ieee-fraud-detection/data>

exploratorio de datos (EDA) y codificación de variables. Este orden garantiza que el EDA se ejecute sobre datos completos y limpios, asegurando igualdad de condiciones entre todas las variables y evitando que los valores faltantes distorsionen los patrones identificados [9].

Como primera etapa, se realizó un diagnóstico integral del conjunto de datos que incluyó la cuantificación del porcentaje de valores faltantes por variable, la identificación de tipos de datos y la evaluación de la correlación de Spearman de cada variable con la variable objetivo *isFraud*. Este diagnóstico reveló patrones de ausencia heterogéneos y estructuralmente diferenciados entre bloques: las variables transaccionales principales presentaron tasas de ausencia inferiores al 5%, el bloque C mostró tasas moderadas de entre el 5% y el 15%, mientras que el bloque D presentó mayor variabilidad con algunos deltas temporales superando el 50% de ausencia. El caso más crítico correspondió al bloque V y a las variables de identidad, con subgrupos que registraron tasas de faltantes superiores al 98% en variables como *id_24* e *id_25*.

Con base en este diagnóstico, se estableció el siguiente criterio de eliminación: toda variable con más del 50% de valores faltantes y correlación absoluta con *isFraud* inferior a 0.05 fue eliminada del análisis, bajo el principio de que imputar masivamente una variable con escasa capacidad predictiva introduce ruido sin aportar valor analítico [9]. Este criterio resultó en la eliminación de 127 variables, reduciendo el conjunto de 434 a 307 variables. Las variables conservadas con alto porcentaje de faltantes pero correlación significativa con *isFraud* fueron objeto de imputación en la siguiente fase.

2.3 Imputación de datos faltantes

Para las variables conservadas con valores faltantes, se diseñó una estrategia de imputación diferenciada siguiendo los lineamientos de Little y Rubin [9]. Previo a la imputación, se crearon 243 variables indicadoras binarias (*_was_null*) para preservar la información contenida en el patrón de ausencia de cada variable, ampliando la matriz de 307 a 550 variables. Esta técnica permite que etapas posteriores capturen la información del patrón de faltantes como atributo predictivo [9].

Para las variables del bloque D (*D2*, *D4*, *D5*, *D7*, *D8*, *D9*, *D10*, *D15*) —variables altamente interrelacionadas según el análisis de correlación— se aplicó el *KNNImputer* de *scikit-learn* con $k = 5$ vecinos, procesando 8 variables de forma multivariada. Previo a la imputación se aplicó escalamiento MinMax temporal para equilibrar las distancias geométricas entre variables de diferente magnitud, revertiéndose al finalizar para recuperar las unidades originales. Este enfoque multivariado preserva las relaciones de correlación entre variables en lugar de imputar cada columna de forma independiente [9]. Las 205 variables numéricas restantes se imputaron con la mediana de cada columna, y las 30 variables categóricas se imputaron asignando la etiqueta '*Unknown*', codificando explícitamente la ausencia como categoría propia. Al finalizar el pipeline se verificó que el total de valores nulos remanentes fuera

cero, confirmando la integridad del proceso. La estructura final antes de la codificación fue de 155,504 registros y 551 variables.

La creación de 243 indicadores de ausencia incrementó temporalmente la dimensionalidad del conjunto de datos de 307 a 550 variables. Aunque esto supone un aumento significativo en el número de atributos, permite preservar información relacionada con los patrones de ausencia, aspecto especialmente relevante en problemas de fraude donde la falta de información puede constituir una señal tan importante como el propio valor observado.

La estrategia de imputación fue diseñada para minimizar el riesgo de introducir sesgos artificiales. Las variables imputadas mediante KNN correspondieron exclusivamente a atributos con relaciones estructurales evidenciadas en el análisis de correlación, mientras que la imputación por mediana se reservó para variables con menor dependencia multivariada. Finalmente, la imputación categórica mediante la categoría '*Unknown*' evitó la pérdida de información asociada a registros incompletos.

Como resultado, el pipeline logró eliminar la totalidad de valores faltantes presentes en la matriz de datos, obteniendo un conjunto completamente consistente para las etapas posteriores de análisis exploratorio y modelado.

2.4 Análisis Exploratorio de Datos (EDA)

El análisis exploratorio de datos (EDA) es definido por Tukey [7] como el conjunto de técnicas dirigidas a examinar los datos con el fin de descubrir estructuras subyacentes, detectar anomalías y verificar supuestos antes de aplicar técnicas de modelado formal. En este proyecto, el EDA se ejecutó íntegramente sobre el dataset limpio e imputado, garantizando igualdad de condiciones entre todas las variables y trabajando con el 100% de los registros disponibles (155,504). El análisis se estructuró en tres niveles de profundidad complementarios.

Análisis univariado: El análisis univariado estudia cada variable de forma independiente para describir su distribución, forma y comportamiento central [10]. Se analizó la variable objetivo *isFraud* de forma independiente mediante un gráfico de conteo con etiquetas de porcentaje para cuantificar el desbalance de clases. Para *TransactionAmt* y *TransactionDT* se calcularon medidas de tendencia central (media, mediana), dispersión (desviación estándar) y forma (asimetría y curtosis) mediante *scipy.stats*, visualizándose mediante histogramas con curva KDE y líneas de referencia. Adicionalmente, se analizó la distribución porcentual de fraude por rangos de monto para evaluar si el valor de la transacción es discriminante entre clases.

Análisis bivariado: El análisis bivariado examina la relación entre dos variables simultáneamente, permitiendo identificar dependencias y diferencias de comportamiento entre grupos [10]. Se analizaron las tasas de fraude y no fraude (visualizadas como porcentaje de clase dentro de cada categoría) para las variables *card4* (franquicia de tarjeta), *ProductCD* (tipo de producto) y *DeviceType* (tipo de dispositivo), mostrando el porcentaje de fraude y no fraude simultáneamente en todas las visualizaciones. Para

DeviceType se ejecutó además una prueba de independencia Chi-cuadrado (χ^2) con cálculo de la V de Cramér para cuantificar estadísticamente la fuerza de asociación con *isFraud*.

Análisis multivariado: El análisis multivariado estudia simultáneamente tres o más variables para descubrir estructuras latentes y patrones de correlación conjunta [11]. Se calculó la correlación de Spearman de todas las variables numéricas respecto a *isFraud*, identificando las 15 variables más relacionadas con la variable objetivo. Sobre este subconjunto se construyó una matriz de correlación de Spearman completa, visualizada mediante un mapa de calor con escala bicromática (-1 a 1), permitiendo identificar tanto la relación individual con el fraude como las intercorrelaciones entre predictores.

2.5 Detección de valores atípicos

La detección de valores atípicos se realizó sobre el dataset completo de 155,504 registros, aplicando tres técnicas con enfoques metodológicos distintos sobre las variables *TransactionAmt* y *CI* [12].

Rango Inter cuartilico (IQR): Enfoque estadístico univariado que identifica como atípicos los registros que superan el límite superior $Q3 + 1.5 \times IQR$ sobre *TransactionAmt*. Es robusto ante distribuciones asimétricas y no requiere supuestos de normalidad [12].

Isolation Forest: Algoritmo de ensamble basado en árboles de aislamiento que detecta anomalías multivariadas según la facilidad con que una observación puede ser aislada del resto. Se configuró con tasa de contaminación del 3%, coherente con la prevalencia de fraude del dataset, y semilla aleatoria fija (*random_state=42*) para reproducibilidad. Previo a la ejecución se aplicó *StandardScaler* para equilibrar las magnitudes de las variables [12].

k-Nearest Neighbors (k-NN) basado en distancias: Enfoque de densidad local que calcula el promedio de distancias a los 5 vecinos más cercanos de cada registro (*n_neighbors=5*). Se estableció como atípico todo registro cuyo score superase el percentil 97 de la distribución de distancias, equivalente a un nivel de contaminación simétrico al utilizado en Isolation Forest.

Los resultados se visualizaron en un panel comparativo de diagramas de dispersión en escala logarítmica y se realizó un cruce evaluativo con *isFraud* para determinar qué porcentaje de fraudes reales capturaba cada técnica. Los valores atípicos detectados no fueron eliminados del dataset dado que en el contexto del fraude financiero los valores extremos pueden ser precisamente la señal del fraude [5].

2.6 Codificación de variables categóricas

Como etapa final del preprocesamiento, se aplicó codificación *Label Encoding* sobre las 31 variables categóricas (tipo *object*) presentes en el dataset limpio, utilizando *LabelEncoder* de scikit-learn. Este método asigna un valor entero único a cada categoría observada, transformando variables como *ProductCD* (categorías: W, H, C, S, R), *card4* (discover, mastercard, visa, american express, Un-

known), *card6* (credit, debit, Unknown, debit or credit, charge card) y *DeviceType* (Unknown, mobile, desktop), entre otras. Al finalizar la codificación, el dataset quedó compuesto por 155,504 registros y 309 variables, distribuidas en 272 de tipo *float64*, 35 de tipo *int64* y 2 de tipo *category*, todas numéricas y listas para etapas de modelado predictivo.

2.7 Herramientas y librerías utilizadas

El desarrollo del proyecto se realizó en Python 3.11 mediante Google Colaboratory (Colab), entorno de notebooks Jupyter alojado en la nube de Google que no requiere instalación local, provee acceso a recursos computacionales (CPU/GPU) y dispone de las librerías de ciencia de datos preinstaladas en su imagen de ejecución, facilitando el trabajo colaborativo y la documentación integrada de cada etapa del proceso analítico.

Las librerías empleadas fueron seleccionadas por su consolidación en la comunidad científica de ciencia de datos y por la complementariedad de sus funcionalidades en el contexto del proyecto. *pandas* (v2.1.4) constituyó la herramienta principal para la manipulación del dataset, incluyendo la integración de los archivos mediante *left join*, el filtrado por criterios de calidad y el cálculo de estadísticas por subconjuntos de variables. *numpy* (v1.26.4) soportó las operaciones numéricas de bajo nivel, el cálculo de percentiles para los umbrales de detección de atípicos y las transformaciones matriciales requeridas en el pipeline de imputación.

Para la visualización, *matplotlib* (v3.10.0) permitió la generación de histogramas con curvas KDE, paneles comparativos de dispersión en escala logarítmica y gráficas de referencia con líneas de media y desviación estándar. *seaborn* (v0.13.2) complementó estas visualizaciones con mapas de calor para las matrices de correlación de Spearman, gráficas de densidad KDE segmentadas por clase y diagramas de barras apiladas con porcentaje de fraude y no fraude por categoría, aprovechando su integración nativa con *pandas*.

scikit-learn (v1.6.0) fue la librería de mayor alcance funcional en el proyecto: proveyó el *KNNImputer* para la imputación multivariada del bloque D; el algoritmo *Isolation Forest* para la detección de anomalías multivariadas; *NearestNeighbors* para el método k-NN de detección de atípicos; *StandardScaler* para el escalamiento previo a Isolation Forest y k-NN; y *LabelEncoder* para la codificación de variables categóricas. Finalmente, *scipy* (v1.13.1) fue empleada para el cálculo de estadísticos de forma mediante *scipy.stats* —asimetría y curtosis— y para la ejecución de la prueba Chi-cuadrado (χ^2) de independencia entre *DeviceType* e *isFraud*, incluyendo el cálculo de la V de Cramér como medida de fuerza de asociación.

3 RESULTADOS Y ANÁLISIS

Se presentan los hallazgos obtenidos a lo largo del proceso de diagnóstico, limpieza, análisis exploratorio y codificación de datos, en correspondencia con las etapas

metodológicas descritas. El análisis se ejecutó sobre el dataset completo de 155,504 registros, garantizando que todos los resultados reflejan el comportamiento real del fenómeno sin restricciones de muestra. Cada hallazgo se acompaña de su interpretación crítica en el contexto de la detección de fraude financiero.

3.1 Caracterización general y variable objetivo

El dataset integrado resultó en una matriz inicial de 155,504 registros y 434 variables, distribuidas en 399 de tipo *float64*, 31 de tipo *object* (categóricas) y 4 de tipo *int64*. El análisis independiente de la variable objetivo *is-Fraud* evidenció un desbalance severo de clases: 151,332 transacciones legítimas (97.32%) y 4,172 transacciones fraudulentas (2.68%), como se ilustra en la Fig. 1.




Fig. 1. Distribución de la variable objetivo

Desde una perspectiva crítica, este desbalance tiene implicaciones directas para cualquier etapa de modelado futura: un clasificador trivial que etiquete todas las transacciones como legítimas alcanzaría una precisión del 97.32%, lo que hace que la exactitud simple sea una métrica irrelevante y obliga al uso de métricas como precisión, recall, F1-score o AUC-ROC para evaluar el desempeño real de detección [5].

3.2 Diagnóstico de valores faltantes y criterio de eliminación

El diagnóstico de valores faltantes reveló patrones de ausencia heterogéneos y estructuralmente diferenciados entre bloques de variables. Las variables de identidad presentaron las tasas más críticas, con variables como *id_24* e *id_25* superando el 98% de ausencia. El bloque V mostró subgrupos con tasas superiores al 70%, mientras que las variables transaccionales principales presentaron tasas inferiores al 5%. La Fig. 2 ilustra el top 50 de variables con mayor porcentaje de valores faltantes.

Aplicando el criterio de eliminación definido —más del 50% de valores faltantes y correlación absoluta con *is-Fraud* inferior a 0.05— se eliminaron 127 variables, reduciendo el conjunto de 434 a 307 variables. Este criterio dual es metodológicamente más riguroso que eliminar únicamente por porcentaje de ausencia, ya que preserva variables con alta tasa de faltantes cuando estas demuestran correlación significativa con la variable objetivo. La




Fig. 2. Top 50 variables con mayor porcentaje de valores faltantes

Fig. 3 muestra el resultado del diagnóstico comparativo entre porcentaje de faltantes y correlación con *isFraud* para las variables evaluadas.

El análisis de los patrones de ausencia permitió identificar diferencias importantes entre los distintos bloques de variables. Las variables de identidad registraron los mayores porcentajes de valores faltantes, superando en algunos casos el 98%, lo cual se explica por la naturaleza relacional del conjunto de datos, donde únicamente una fracción de las transacciones posee información complementaria de identidad. Por otro lado, las variables del bloque V presentaron niveles elevados de ausencia que oscilan entre el 60% y el 80%, sugiriendo que muchas de estas características fueron capturadas únicamente bajo condiciones específicas del proceso transaccional.

La combinación del porcentaje de valores faltantes con la correlación respecto a la variable objetivo permitió evitar decisiones basadas únicamente en la calidad estructural de la información. Variables como *id_21* y *V7* presentaron altos niveles de ausencia, pero conservaron una asociación relevante con el fraude, motivo por el cual fueron preservadas para etapas posteriores de imputación. Este enfoque permitió equilibrar la reducción de dimensionalidad con la conservación de información potencialmente predictiva.

	variable	porcentaje_faltantes	correlacion_isFraud	accion
0	id_24	98.608396	-0.039057	Eliminar
1	id_25	98.506791	-0.022620	Eliminar
2	id_21	98.501646	0.053618	Conservar o evaluar
3	id_07	98.499717	-0.030171	Eliminar
4	id_26	98.499717	0.042264	Eliminar
...	...	...	...	...
75	V338	70.417481	0.007676	Eliminar
76	V336	70.417481	0.018776	Eliminar
77	V1	68.979576	0.001325	Eliminar
78	D11	68.979576	-0.041673	Eliminar
79	V7	68.979576	0.057801	Conservar o evaluar

Fig. 3. DataFrame con variable, porcentaje faltantes, correlación *isFraud* y acción

Críticamente, la decisión de no imputar variables con más del 50% de faltantes y baja correlación responde a un principio fundamental del análisis de datos: imputar masivamente una variable sin capacidad predictiva introduce ruido artificial que puede distorsionar los patrones reales del fenómeno estudiado [9].

3.3 Resultados del análisis exploratorio univariado

El análisis univariado de *TransactionDT* reveló una distribución aproximadamente simétrica con asimetría de -0.03 y curtosis de -0.99 , indicando una forma platicúrtica sin colas pesadas. La media fue de 1,645,176.74 s con una desviación estándar de 791,754.59 s, abarcando un rango de 86,400 s a 3,211,793 s. La presencia de una distribución bimodal visible en la Fig. 4 sugiere que el periodo de observación captura dos franjas temporales de mayor actividad transaccional, posiblemente relacionadas con comportamientos de compra estacionales o ciclos de facturación.




Fig. 4. Histograma con KDE, líneas de media y desviación estándar, distribución bimodal

El análisis de *TransactionAmt* evidenció una distribución fuertemente asimétrica positiva con asimetría de 6.93 y curtosis de 74.19, valores que indican la presencia de una cola derecha extremadamente larga y comportamiento leptocúrtico (Fig. 5). La media de USD 127.41 con un máximo de USD 5,094.95 y un mínimo de USD 0.29 confirma que la mayoría de transacciones se concentran en montos bajos-medios. Una curtosis de 74.19 tiene tres implicaciones metodológicas directas: primero, invalida el uso de la media como estimador central confiable; segundo, hace al método Z-score poco confiable como detector de atípicos para esta variable específica, ya que la desviación estándar queda inflada por los valores extremos; y tercero, valida la necesidad de aplicar transformación logarítmica antes de cualquier proceso de modelado, dado que algoritmos sensibles a la magnitud de las variables serían dominados por los montos extremos en su forma original [13].




Fig. 5. Distribución TransactionAmt Histograma con KDE

El análisis de la distribución porcentual de fraude por rangos de monto reveló que la tasa de fraude se mantiene

relativamente estable entre rangos (entre 1.0% y 3.9%), sin mostrar una tendencia clara al alza conforme aumenta el monto. El rango de USD (0.291, 25.419] presentó una tasa de fraude del 3.9%, mientras que el rango USD (75.0, 100.0] mostró la tasa más baja con 1.0%. Este hallazgo es crítico: contradice la intuición común de que las transacciones de mayor monto son más fraudulentas, confirmando que el monto por sí solo no es un predictor confiable del fraude [5].

3.4 Resultados del análisis bivariado

El análisis por franquicia de tarjeta (*card4*) mostró diferencias en las tasas de fraude entre redes de pago (Fig. 6): Discover presentó la mayor tasa con 3.4%, seguida de Mastercard (3.0%), Visa (2.6%) y American Express con la tasa más baja (1.1%). La brecha entre American Express y el resto es especialmente relevante, ya que su tasa de fraude es casi tres veces menor que la de Discover, lo que podría reflejar diferencias en los protocolos de seguridad y verificación de cada red de pago, o en el perfil socioeconómico de sus usuarios.




Fig. 6. Fraude por franquicia card4

El análisis por *ProductCD* (Fig. 7) evidenció la mayor heterogeneidad de riesgo entre todas las variables categóricas evaluadas. La categoría C registró una tasa de fraude del 8.71%, superando en 3.2 veces la tasa general del dataset (2.68%) y siendo la variable categórica con mayor poder discriminante identificada en el análisis bivariado. Las demás categorías presentaron tasas considerablemente menores: S (3.49%), H (2.11%), W (1.83%) y R (1.30%). Dado que las categorías de *ProductCD* son anónimas por acuerdo de confidencialidad con Vesta Corporation, no es posible determinar el tipo de producto que representa la categoría C; sin embargo, su sola presencia multiplica por 3.2 la probabilidad basal de fraude, lo que la convierte en un predictor categórico de alto riesgo que debería recibir tratamiento diferenciado en cualquier sistema de puntuación de riesgo.

El análisis por *DeviceType* (Fig. 8) mostró que los dispositivos móviles presentan una tasa de fraude del 5.45%, significativamente mayor que los dispositivos de escritorio (2.99%), representando un riesgo relativo 1.82 veces superior. Esta diferencia fue sometida a contraste estadístico formal mediante la prueba Chi-cuadrado de independencia aplicada sobre una tabla de contingencia de 61,044 registros con información de dispositivo disponible,




Fig. 7. Fraude por ProductCD

arrojando los siguientes resultados: $\chi^2(1) = 228.3362$, $p = 1.3747 \times 10^{-51}$, V de Cramér = 0.0612. El estadístico Chi-cuadrado con un p-valor prácticamente nulo permite rechazar con plena confianza estadística la hipótesis nula de independencia. Sin embargo, la V de Cramér de 0.0612 revela que la fuerza de asociación es débil, lo que indica que *DeviceType* es un predictor relevante pero insuficiente por sí solo para discriminar el fraude: su valor reside en la combinación con otras variables dentro de un modelo multivariado. Esta distinción entre significancia estadística y relevancia práctica es fundamental en datasets de gran tamaño, donde incluso asociaciones débiles alcanzan significancia por el volumen de registros [10].




Fig. 8. Fraude por DeviceType

3.5 Resultados del análisis multivariado

El cálculo de la correlación de Spearman de todas las variables numéricas respecto a *isFraud* identificó que las variables más relacionadas con el fraude pertenecen al bloque Vesta (V), específicamente V244 ($r_s = 0.340$), V242 ($r_s = 0.314$), V246 ($r_s = 0.312$) y V243 ($r_s = 0.309$), como variables con mayor correlación positiva con *isFraud*. Este resultado es significativamente diferente al encontrado en análisis parciales con subconjuntos de datos, donde el bloque C aparecía como el más correlacionado, evidenciando la importancia de trabajar con el dataset completo para obtener conclusiones representativas.

La matriz de correlación de Spearman sobre las 15 variables más relacionadas con *isFraud* (Fig. 9) reveló además intercorrelaciones muy elevadas dentro del bloque

V: V232 y V233 presentan $r_s = 0.97$, V230 y V229 muestran $r_s = 0.91$, y V231 y V233 registran $r_s = 0.96$. Estas correlaciones internas superiores a 0.85 constituyen colinealidad crítica que genera redundancia informática y que debe abordarse mediante reducción de dimensionalidad antes de cualquier modelado predictivo, dado que mantener variables prácticamente intercambiables en un modelo introduce multicolinealidad severa [11].

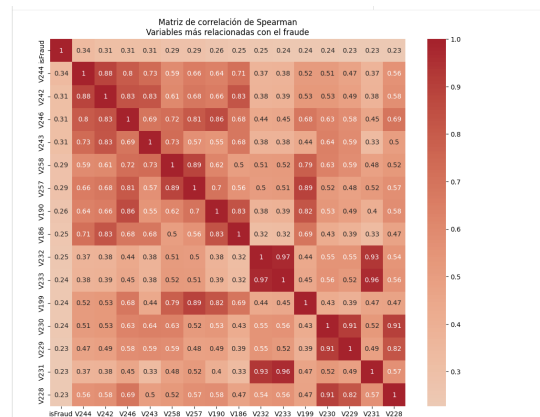


Fig. 9. Matriz correlación Spearman

3.6 Resultados de la detección de valores atípicos

La comparación de las tres técnicas de detección sobre los 155,504 registros completos (Fig. 10) reveló diferencias sustanciales en el volumen de atípicos detectados y en su capacidad de captura de fraudes reales. El método IQR detectó 15,184 registros atípicos, capturando 578 fraudes reales (3.81% de fraudes dentro de los atípicos). Isolation Forest detectó 4,665 atípicos con 287 fraudes reales (6.15%), mientras que k-NN identificó 4,666 atípicos con 340 fraudes reales (7.29%).

El IQR detectó 3.25 veces más atípicos que los métodos de machine learning, pero con la tasa de fraude más baja dentro de los atípicos (3.81%), evidenciando una alta tasa de falsos positivos: la mayoría de los 15,184 registros marcados como atípicos son transacciones de monto elevado legítimas, no fraudes. Isolation Forest y k-NN, al evaluar la anomalía en el espacio bidimensional (monto, conteo C1) considerando la densidad local, lograron mayor precisión relativa con tasas del 6.15% y 7.29% respectivamente. Críticamente, ningún método capturó más del 7.29% de los fraudes al buscar atípicos, lo que confirma que el fraude en este dataset no se manifiesta principalmente como una anomalía geométrica simple sino como una combinación sutil de comportamientos en múltiples dimensiones que requiere modelos supervisados para su detección efectiva [5]. Los valores atípicos detectados no fueron eliminados: se preservaron como señal potencialmente explotable en etapas de modelado.




Fig. 10. Comparativa de técnicas de detección de valores atípicos: IQR, Isolation Forest y k-NN

3.7 Variables influyentes en el fraude financiero

La integración de los resultados del análisis bivariado y multivariado permite concluir cuáles son las características con mayor influencia en la ocurrencia de fraude financiero en este dataset. Las variables del bloque Vesta encabezan el ranking de correlación con *isFraud*: V244 ($r_s = 0.340$), V242 ($r_s = 0.314$), V246 ($r_s = 0.312$), V243 ($r_s = 0.309$), V258 ($r_s = 0.286$) y V257 ($r_s = 0.285$) son las seis variables con mayor poder predictivo individual identificadas en el análisis. Aunque estas variables son anónimas, su alta correlación consistente sugiere que capturan patrones de comportamiento del usuario o del dispositivo directamente asociados con actividad fraudulenta.

En el plano categórico, *ProductCD* categoría C (8.71% de fraude) y *DeviceType* móvil (5.45% de fraude, $\chi^2 = 228.34$, $p = 1.37 \times 10^{-51}$) son los predictores categóricos más relevantes identificados. Notablemente, el monto de la transacción (*TransactionAmt*) demostró ser un predictor débil: la distribución porcentual de fraude por rangos de monto no muestra una tendencia clara y su correlación de Spearman con *isFraud* es marginal, confirmando que el fraude financiero en e-commerce no se detecta por el valor económico de la operación sino por patrones de comportamiento multidimensionales [5].

3.8 Limitaciones del estudio

A pesar de los hallazgos obtenidos, el presente trabajo presenta algunas limitaciones que deben considerarse al interpretar los resultados. En primer lugar, el conjunto de datos utilizado corresponde a información anonimizada, por lo que no es posible conocer el significado real de numerosas variables del bloque Vesta. Esta restricción limita la interpretación de negocio de las correlaciones encontradas.

En segundo lugar, el análisis realizado tuvo un enfoque exploratorio y descriptivo, por lo que no se desarrollaron modelos predictivos capaces de cuantificar directamente la capacidad de clasificación de las variables identificadas como relevantes.

Adicionalmente, la estrategia de reducción de dimensionalidad basada en porcentaje de valores faltantes y correlación con la variable objetivo, aunque metodológicamente justificada, podría eliminar variables

que aporten información útil únicamente cuando interactúan con otros atributos dentro de modelos multivariados más complejos.

Los resultados obtenidos evidencian que el fraude financiero no puede explicarse mediante una única variable, como el monto o el momento de la transacción. Por el contrario, surge de la interacción de múltiples factores que solo pueden ser identificados mediante técnicas de análisis de datos. Esto demuestra el valor de la ciencia de datos en contextos de gestión de riesgo, ya que permite detectar relaciones ocultas, priorizar variables relevantes y generar evidencia cuantitativa para el diseño de sistemas automatizados de prevención y detección de fraude.

Finalmente, los resultados obtenidos corresponden a un conjunto de datos específico del contexto de comercio electrónico estadounidense y, por tanto, no deben generalizarse automáticamente a otros sectores o regiones sin realizar procesos de validación adicionales.

4 CONCLUSIONES

El análisis realizado sobre el conjunto de datos IEEE-CIS Fraud Detection permitió identificar patrones relevantes asociados al fraude financiero y evidenciar la importancia de las etapas de preprocesamiento y análisis exploratorio como fundamento para futuros modelos predictivos. El diagnóstico inicial reveló un marcado desbalance de clases, con únicamente el 2.68% de las transacciones catalogadas como fraudulentas, condición característica de los problemas de detección de fraude y que obliga a considerar métricas de evaluación diferentes a la exactitud tradicional.

La estrategia de limpieza e imputación permitió transformar una matriz inicial de 434 variables en un conjunto de datos consistente y libre de valores faltantes. La eliminación de variables con altos niveles de ausencia y baja relación con la variable objetivo redujo significativamente la complejidad del problema sin comprometer la información relevante para el análisis. Asimismo, la combinación de imputación multivariada mediante KNN, imputación estadística tradicional e indicadores de ausencia permitió conservar información potencialmente útil para etapas posteriores de modelado.

Los resultados del análisis exploratorio evidenciaron que el fraude financiero no depende únicamente del monto de la transacción. Aunque TransactionAmt presentó una distribución altamente asimétrica y con valores extremos, la tasa de fraude se mantuvo relativamente estable entre los diferentes rangos de monto, indicando que el valor económico de una operación no constituye por sí solo un predictor confiable del fraude. Este hallazgo confirma que el fenómeno estudiado responde a patrones multidimensionales más complejos.

En el análisis bivariado se identificaron diferencias importantes entre categorías. La variable ProductCD mostró el mayor poder discriminante entre las variables categóricas analizadas, destacándose la categoría C con una tasa de fraude considerablemente superior al promedio general del conjunto de datos. De igual forma, los dispositivos móviles presentaron una mayor proporción de fraude que los dispositivos de escritorio. Aunque la prueba Chi-cuadrado confirmó una asociación estadísticamente significativa entre DeviceType e isFraud, la magnitud del efecto fue reducida, lo que indica que esta variable debe interpretarse en conjunto con otras características y no de manera aislada.

El análisis multivariado permitió identificar que las variables con mayor relación con el fraude pertenecen principalmente al bloque Vesta, destacándose V244, V242, V246 y V243 como los atributos más correlacionados con la variable objetivo. Adicionalmente, se detectaron altos niveles de colinealidad entre varios atributos de este bloque, situación que sugiere la necesidad de aplicar técnicas de reducción de dimensionalidad o selección de características antes de construir modelos predictivos, con el fin de evitar redundancias y mejorar la eficiencia computacional.

La comparación entre los métodos de detección de valores atípicos evidenció que los registros extremos no necesariamente corresponden a actividades fraudulentas. Aunque Isolation Forest y k-NN mostraron una mayor capacidad relativa para concentrar fraudes dentro de los registros detectados como atípicos, ninguno de los métodos logró capturar una proporción significativa de los fraudes totales. Este resultado confirma que el fraude financiero en comercio electrónico no puede entenderse únicamente como un problema de anomalías extremas, sino como un fenómeno complejo que requiere enfoques supervisados capaces de modelar múltiples patrones de comportamiento simultáneamente.

A pesar de los resultados obtenidos, el estudio presenta algunas limitaciones que deben ser consideradas. En primer lugar, el conjunto de datos utilizado corresponde a información anonimizada, lo que impide interpretar directamente el significado de numerosas variables del bloque Vesta y limita el análisis desde una perspectiva de negocio. En segundo lugar, el trabajo tuvo un enfoque principalmente exploratorio y de preparación de datos, por lo que no se desarrollaron modelos predictivos que permitieran cuantificar el impacto individual o conjunto de las variables identificadas como relevantes. Finalmente, aunque las estrategias de imputación y reducción de dimensionalidad fueron diseñadas para preservar la mayor cantidad posible

de información útil, siempre existe el riesgo de que algunas relaciones complejas entre variables no sean completamente capturadas mediante técnicas exploratorias tradicionales.

Como trabajo futuro, se recomienda utilizar el conjunto de datos preprocesado obtenido en esta investigación para construir y comparar modelos de clasificación supervisada, evaluando técnicas como Random Forest, Gradient Boosting, XGBoost, Redes Neuronales y Máquinas de Soporte Vectorial, con el propósito de desarrollar sistemas de detección de fraude más precisos y aplicables a escenarios reales de monitoreo transaccional.

En términos generales, el trabajo permitió transformar un conjunto de datos complejo, altamente dimensional y con elevados niveles de ausencia en una matriz limpia, consistente y apta para procesos de modelado predictivo. Los resultados obtenidos evidencian que el fraude financiero es un fenómeno multifactorial cuya comprensión requiere integrar variables transaccionales, comportamentales y relacionales. De esta manera, el análisis realizado constituye una base sólida para el desarrollo de sistemas inteligentes de detección de fraude capaces de apoyar procesos de monitoreo y gestión de riesgo en entornos reales de comercio electrónico.

5 REFERENCES

- [1] The Nilson Report, "Payment Card Fraud Losses Worldwide in 2023," Tech. Rep. 11, HSN Consultants, Inc. (2025), issue 1296, January 2025.
- [2] FICO, "Card-Not-Present Fraud Remains a Leading Concern as Payment Systems Evolve," <https://www.fico.com/blogs/card-not-present-fraud-remains-leading-concern-payment-systems-evolve> (2025), accessed: May 24, 2026.
- [3] LexisNexis Risk Solutions, "El verdadero costo del fraude en América Latina," <https://risk.lexisnexis.com/global/es/about-us/press-room/press-release/20240620-true-cost-of-fraud-colombia> (2024).
- [4] F. Provost and T. Fawcett, *Data Science for Business*, 2 (O'Reilly Media, 2013).
- [5] A. D. Pozzolo, O. Caelen, R. A. Johnson, and G. Bontempi, "Calibrating probability with undersampling for unbalanced classification," in *Proc. IEEE Symp. Comput. Intell. Data Mining (CIDM)*, 4, pp. 159–166, Orlando, FL (2015).
- [6] J. VanderPlas, *Python Data Science Handbook*, 3 (O'Reilly Media, 2016).
- [7] J. W. Tukey, *Exploratory Data Analysis*, 5 (Addison-Wesley, Reading, MA, 1977).
- [8] Kaggle, "IEEE-CIS Fraud Detection," <https://www.kaggle.com/competitions/ieee-fraud-detection/data> (2019), accessed: May 22, 2026.
- [9] R. J. A. Little and D. B. Rubin, *Statistical Analysis with Missing Data*, 9 (Wiley, Hoboken, NJ, 2019), 3rd ed.
- [10] R. Johnson and D. Wichern, *Applied Multivariate Statistical Analysis*, 6 (Pearson Prentice Hall, Upper Saddle River, NJ, 2007), 6th ed.

- [11] J. F. Hair, W. C. Black, B. J. Babin, and R. E. Anderson, *Multivariate Data Analysis*, 7 (Cengage Learning, 2019), 8th ed.
- [12] D. C. Hoaglin, F. Mosteller, and J. W. Tukey, *Understanding Robust and Exploratory Data Analysis*, 8 (Wiley, New York, 1983).
- [13] W. McKinney, *Python for Data Analysis*, 10 (O'Reilly Media, Sebastopol, CA, 2022), 3rd ed.